



دانشگاه تهران  
پردیس دانشکده های فنی  
دانشکده مهندسی برق و  
کامپیوتر



ارائه سیستم پیش بینی قیمت بیت کوین

پروژه کارشناسی مهندسی نرم افزار گرایش نرم افزار

نسترن علی پور

۸۱۰۱۹۶۵۱۵

استاد راهنما:  
دکتر هشام فیلی

شهریور ۱۴۰۰

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

تعهدنامه اصالت اثر  
باسمه تعالی

اینجانب نسترن علی پور تائید می کنم که مطالب مندرج در این پایان نامه حاصل تلاش اینجانب است و به دستاوردهای پژوهشی دیگران که در این نوشته از آنها استفاده شده است مطابق مقررات ارجاع گردیده است. این پایان نامه قبلاً برای احراز هیچ مدرک هم سطح یا بالاتر ارائه نشده است.  
کلیه حقوق مادی و معنوی این اثر متعلق به دانشکده فنی دانشگاه تهران می باشد.

نام و نام خانوادگی دانشجو: نسترن علی پور

امضای دانشجو:

## تشکر و قدردانی:

.....

.....

خداوند منان را شاکرم که موهبت‌های فراوان به من عطا کرده است و مرا در مسیر دانش قرار داده است. از پشتوانه‌های زندگی‌ام، پدر، مادر و خواهر دلسوزم سپاس گزارم که همواره در این مسیر مشوق من بوده‌اند و نور امید را در وجودم زنده نگه داشتند. از استاد بزرگوارم، دکتر فیلی بابت تمام زحماتشان کمال تشکر را دارم.

## چکیده

پیش بینی سری های زمانی مالی، مانند سهام و ارز، یکی از مسائلی است که امروزه محققان زیادی به آن علاقه نشان داده اند. یکی از این سری های زمانی محبوب برای پیش بینی، پیش بینی قیمت بیت کوین می باشد. ماهیت غیر خطی و نوسانات زیاد، از چالش های پیش بینی قیمت بیت کوین است. مطالعات زیادی در مورد پیش بینی سری های مالی به ویژه در پیش بینی ارز های رمزنگاری شده انجام شده است، اما بیشتر این مطالعات بر روی داده های بیت کوین در سال هایی که نوسانات محدودتری وجود داشت انجام گرفته است. شبکه های حافظه کوتاه مدت (LSTM) یک دنباله پیشرفته در یادگیری عمیق برای پیش بینی سری های زمانی هستند. در پژوهش ما قصد داریم تا با آموزش مدل های یادگیری عمیق LSTM و GRU با استفاده از داده های نوسانی ماه های اخیر، تأثیر این مدل ها را در پیش بینی قیمت بیت کوین بررسی کنیم. برای این منظور داده های ۱۵ دقیقه ای و روزانه قیمت بیت کوین را جمع آوری کرده ایم و با هر نوع داده، مدل های LSTM و GRU را آموزش داده ایم. در نهایت مشاهده کردیم که مدل ها دقت بالایی دارند. در نهایت برای اطمینان از کیفیت پیش بینی مدل ها، استراتژی های خرید و فروش تعریف کردیم و با استفاده از قیمت پیش بینی شده، به معامله پرداختیم اما سود حاصل از استفاده ی آنها، مقادیر قابل قبولی نبود. در نهایت با توجه به وجود خطا در مدل ها، استفاده از استراتژی های ساده برای خرید و فروش ممکن است باعث ضرر زیادی شود و باید برای داشتن استراتژی های پیچیده تر، با توجه به درصد اطمینان از پیش بینی قیمت، سیگنال های مورد نظر را تولید کرد.

## کلمات کلیدی:

بیت کوین، یادگیری عمیق، رمز ارز، پیش بینی سری های  
زمانی، تحلیل تکنیکال

## فهرست مطالب

<b>11</b>	<b>مقدمه</b>
<b>16</b>	<b>مروری بر مطالعات انجام شده</b>
<b>17</b>	<b>۱/۲ روش های سنتی</b>
17	1.1.۲ اندیکاتور ها
18	۲/۱/۲ مدل ARIMA
<b>19</b>	<b>2.2 مدل های یادگیری ماشین پیچیده</b>
20	۱/۲/۲ مدل SVR
21	۲/۲/۲ مدل های RNN
22	۳/۲/۲ مدل LSTM
23	۴/۲/۲ مدل GRU
<b>25</b>	<b>روش تحقیق</b>
<b>25</b>	<b>1.3 تعریف مسئله</b>
26	۱/۱/۳ ساخت مدل پیش بینی قیمت بیت کوین
26	۲/۱/۳ ساخت سیستم معامله خودکار

26	..... 2.3 فرآیند جمع آوری داده ها
27	..... ۱/۲/۳ انتخاب منبع داده
29	..... ۲/۲/۳ ذخیره ی داده های جمع آوری شده
29	..... ۳/۳ انتخاب ویژگی های مدل
30	..... ۱/۳/۳ انتخاب اندیکاتور ها
35	..... ۴/۳ فرآیند انتخاب مدل ها
36	..... ۵/۳ پیش پردازش داده ها
36	..... ۱/۵/۳ مهندسی ویژگی ها
37	..... ۲/۵/۳ ارزیابی ویژگی ها
38	..... ۳/۵/۳ تمیز کردن داده ها
38	..... ۴/۵/۳ نرمال سازی داده ها
39	..... ۵/۵/۳ جداسازی داده های تست و آموزش
39	..... ۶/۳ جزئیات پیاده سازی و آموزش مدل ها
40	..... ۱/۶/۳ مدل LSTM
46	..... ۷/۳ ارزیابی مدل ها
46	..... ۱/۷/۳ پیاده سازی سیستم معامله گری خودکار
50	..... نتایج
51	..... ۱/۴ سیستم پیش بینی قیمت بیت کوین
51	..... ۱/۱/۴ نتایج مدل ها
59	..... ۲/۱/۴ مقایسه مدل ها با baseline ها
	..... ۲/۴ نتایج ارزیابی مدل ها توسط سیستم معامله گری
63	..... خودکار
68	..... نتیجه گیری
70	..... مراجع

## فهرست شکل‌ها

شکل ۱/۱: نمودار مقایسه‌ی نوسانات قیمت بیت کوین در مقابل نوسانات قیمت طلا	14
شکل ۱/۲ نمودار تغییرات قیمت بیت کوین در سال‌های اخیر	14
شکل ۱/۴ نمودار پیش‌بینی مدل LSTM روزانه در کنار نمودار مقدار واقعی	52
شکل ۲/۴ نمودار پیش‌بینی مدل LSTM با تایم فریم ۱۵ دقیقه‌ای در کنار نمودار مقدار واقعی	54
شکل ۳/۴ نمودار پیش‌بینی مدل LSTM با تایم فریم ۱۵ دقیقه‌ای برای ۵۰۰ داده‌ی انتهایی تست	54
شکل ۴/۴ نمودار پیش‌بینی مدل GRU با تایم فریم روزانه در کنار نمودار مقدار واقعی	56
شکل ۵/۴ نمودار پیش‌بینی مدل GRU با تایم فریم ۱۵ دقیقه‌ای در کنار نمودار مقدار واقعی	57
شکل ۶/۴ نمودار پیش‌بینی مدل GRU با تایم فریم ۱۵ دقیقه‌ای برای ۵۰۰ داده‌ی انتهایی تست	58
شکل ۷/۴ نمودار مدل SVR با دیتاست روزانه در کنار قیمت واقعی	60
شکل ۸/۴ نمودار مدل SVR با دیتاست با تایم فریم ۱۵ دقیقه‌ای در کنار قیمت واقعی	61
شکل ۹/۴ نمودار اندیکاتور میانگین متحرک ساده با دیتاست روزانه در کنار قیمت واقعی	62
شکل ۱۰/۴ نمودار اندیکاتور میانگین متحرک ساده با دیتاست با تایم فریم ۱۵ دقیقه‌ای در کنار قیمت واقعی	63
شکل ۱۱/۴ نتایج بک تست برای مدل LSTM با تایم فریم روزانه برای ۳۲ روز اخیر داده‌های تست	64
شکل ۱۲/۴ نتایج بک تست بر مدل LSTM با تایم فریم ۱۵ دقیقه‌ای در ۳۲ روز اخیر	65
شکل ۱۳/۴ نتایج بک تست برای مدل GRU با تایم فریم روزانه برای ۳۲ روز اخیر داده‌های تست	66
شکل ۱۴/۴ نتایج بک تست بر مدل GRU با تایم فریم ۱۵ دقیقه‌ای در ۳۲ روز اخیر	67



## فهرست جدول‌ها

جدول ۱/۳ پارامترهای تنظیم شده برای مدل LSTM با تایم فریم روزانه	41
جدول ۲/۳ پارامترهای تنظیم شده برای مدل LSTM با تایم فریم ۱۵ دقیقه‌ای	42
جدول ۳/۳ پارامترهای تنظیم شده برای مدل GRU با تایم فریم روزانه	43
جدول ۴/۳ پارامترهای تنظیم شده برای مدل GRU با تایم فریم روزانه	44
جدول ۱/۴ خطای RMSE مدل‌های LSTM و GRU و MA و SVR	59
جدول ۲/۴ مدت زمان آموزش مدل‌های LSTM و GRU	59



## فصل 1

### مقدمه

بیت کوین از زمانی که برای اولین بار توسط ناکاموتو [1] پیشنهاد گردید، مورد توجه سرمایه گذاران قرار گرفت. دلیل شهرت این ارز، غیر متمرکز بودن آن است که از پروتکل‌های رمزنگاری و توافق غیر متمرکز و مکانیزم‌های دیگر برای تایید تراکنش‌ها استفاده می‌کند. بیت کوین برخلاف ارزهای سنتی، می‌تواند مستقیماً بین دو نفر مبادله شود؛ این امر توسط یک کلید خصوصی و یک کلید عمومی که برای هر معامله، ایجاد می‌شوند، امکان پذیر است. وجود این کلیدها و هویت رمزنگاری شده‌ی افراد، به آنها کمک می‌کند که بدون افشای هویت فیزیکی خود، به معامله بپردازند. علاوه بر این کاربران می‌توانند ارز بیت کوین را با حداقل هزینه پردازش<sup>1</sup> به کشورهای دیگر انتقال دهند و از هزینه‌های هنگفتی که

---

<sup>1</sup> Process Fee

مؤسسات مالی سنتی دریافت می‌کنند، اجتناب کنند. فناوری و شبکه‌ای که بیت کوین از آن استفاده می‌کند، بلاک چین<sup>1</sup> نام دارد. یکی از ویژگی‌های مهم این شبکه، تغییر ناپذیر<sup>2</sup> بودن آن است. به این صورت که اگر معامله‌ای در این شبکه منتشر شود، دیگر نمی‌توان آن را باطل کرد.

کمی پیشتر اشاره شد که بیت کوین یک ارز غیر متمرکز است. به این معنی که توسط هیچ مرجع مرکزی کنترل نمی‌شود و بانک‌ها از مدیریت عرضه‌ی ارز حذف شده‌اند. این امر باعث می‌شود که بیت کوین غیر قابل سانسور باشد. یکی دیگر از ویژگی‌های بیت کوین این است که می‌توان با پروتکل اجتماع آنکه از نوع اثبات کار<sup>3</sup> است، به تصمیمات دموکراتیک دست یافت؛ به این صورت که افراد بدون نیاز به اعتماد به دیگر افراد حاضر در شبکه، می‌توانند با آنها معامله کنند.

یکی دیگر از ویژگی‌های غیرمعمول بیت کوین، نوسانات بسیار زیاد برخلاف دارایی‌های مالی سنتی (مانند طلا و یا سهام) است. یکی از دلایل این نوسانات عدم وجود مرکزیتی است که با عرضه متناسب با نیاز جامعه، قیمت را کنترل کند. برای مثال در تاریخ ۲۰۲۱/۰۵/۱۱ قیمت بیت کوین در حدود ۵۶۵۰۰ دلار بود و در عرض ۸ روز قیمت آن به ۳۶۷۰۰ دلار سقوط کرد. همچنین در شکل ۱/۱ مشاهده می‌کنیم که قیمت بیت کوین نسبت به طلا نوسانات قیمتی بیشتری دارد. این نوسانات غیر معمول و بزرگ

---

<sup>1</sup> Blockchain

<sup>2</sup> Immutable

<sup>3</sup> Proof of Work

باعث شده است که توجه سرمایه گذاران و محققان بسیاری به این رمز ارز جلب شود.

برای تجزیه و تحلیل قیمت بیت کوین دو روش اصلی وجود دارد. اولین روش، تحلیل پایه‌ای<sup>1</sup> است که همان طور که از نامش پیداست با مطالعه عوامل مؤثر در قیمت بیت کوین، به پیش بینی قیمت آن می‌پردازد. این روش بسیار دقیق است [4, 13] اما نیازمند دانش وسیع از تمام متغیرهای دخیل در قیمت بیت کوین است که گاهی تشخیص این متغیرها بسیار دشوار است. روش دیگر، تحلیل تکنیکال نام دارد. این روش تنها با استفاده از داده‌های قیمت در گذشته<sup>2</sup> به پیش بینی قیمت ارز در آینده می‌پردازد. طبیعتاً این روش دقت کمتری را نسبت به روش تحلیل پایه‌ای دارد، اما یافتن متغیرهای مؤثر در قیمت بیت کوین، بیشتر در حوزه‌ی اقتصاد می‌باشد که هدف این تحقیق نیست بنابراین در این تحقیق از تحلیل تکنیکال کمک می‌گیریم.

در سال‌های گذشته مطالعات و تحقیقات زیادی در مورد تجزیه و تحلیل سری زمانی بیت کوین انجام شده است؛ اما بیشتر این تحقیقات در سال‌های ۲۰۱۸ و ۲۰۱۹ (پیش از ماه اکتبر) انجام شده است؛ حال آنکه قیمت بیت کوین در این بازه‌ی زمانی نوسانات کمتری داشته است. (شکل ۱/۲)


---

<sup>1</sup> Fundamental

<sup>2</sup> Historical Data



شکل ۱/۱: نمودار مقایسه‌ی نوسانات قیمت بیت کوین در مقابل نوسانات قیمت طلا



شکل ۱/۲: نمودار تغییرات قیمت بیت کوین در سال‌های اخیر

در این مقاله قصد داریم تا با تحلیل تکنیکال به پیش بینی قیمت بیت کوین بپردازیم. در ابتدا داده های گذشته شامل داده های اخیر که نوسانات زیادی دارند را جمع آوری می کنیم و سپس با استفاده از این داده ها، اندیکاتورهایی را به عنوان ویژگی برای مدل های خود ایجاد می کنیم. سپس ویژگی های مؤثر در مدل های مورد نظر را انتخاب می کنیم و مدل ها را با این ویژگی ها آموزش می دهیم.

در این پژوهش، ابتدا به بررسی و مرور متون و تحقیقات پیشین در این حوزه می پردازیم. سپس روش تحقیق شامل جمع آوری داده های OHLC از صرافی بایننس<sup>1</sup>، به دست آوردن اندیکاتورهای مناسب برای بیت کوین، فیلتر کردن و محدود کردن ویژگی های مناسب برای پیش بینی، انتخاب مدل های مورد نظر و پیش پردازش و آموزش مدل ها، می پردازیم و در انتها بر اساس مقادیر پیش بینی شده، استراتژی خرید و فروش ایجاد می کنیم و طی بک تست<sup>2</sup> میزان مفید بودن مدل ها برای معامله کردن با آنها را ارزیابی می کنیم.

---

<sup>1</sup> Binance

<sup>2</sup> Back Test

## فصل 2

# مروری بر مطالعات انجام شده

پیش بینی سری های زمانی، در ابتدای پیدایش بر اساس مدل های ساده و خطی مانند میانگین متحرک<sup>1</sup> انجام میشد. اما با

---

<sup>1</sup> Moving Average



پیدایش هوش مصنوعی و یادگیری عمیق عصر جدیدی برای پیش بینی سری زمانی آغاز شد. در ادامه روش‌های سنتی و سپس تعدادی روش‌های جدید در هوش مصنوعی برای پیش بینی قیمت بیت کوین را شرح می‌دهیم.

## ۱/۲ روش‌های سنتی

### 1.1.۲ اندیکاتورها

پیشتر گفتیم تحلیل تکنیکال روشی برای ارزیابی سری زمانی مالی با استفاده از نمودارها و داده‌هایی مانند قیمت و حجم معاملات است. این نوع تحلیل سعی دارد از نمودارها و سایر ابزارها برای تشخیص الگوها استفاده کند و پیشنهادهایی برای آینده ارائه دهد. بسیاری از معامله‌گران با استفاده از نمودارهایی موسوم به اندیکاتورها، به تحلیل وضعیت فعلی قیمت و پیش بینی قیمت در آینده می‌پردازند. اندیکاتورها با استفاده از محاسبات ریاضی بر روی قیمت سری زمانی و حجم معاملات آن، اطلاعات بسیار خوبی در مورد آن ارز، از جمله شتاب قیمتی، روند حرکتی و سایر معیارهای مهم ارائه می‌دهند. معمولاً از اندیکاتورها برای تایید و اعتبارسنجی روند ارز استفاده می‌شود که در نهایت با به‌کارگیری اندیکاتورهای دیگر، منجر به سیگنال خرید و فروش می‌گردد. اندیکاتورها به دو دسته پیشرو<sup>1</sup> و دنباله‌رو<sup>2</sup> تقسیم می‌شوند. اندیکاتورهای پیشرو به‌طور معمول همراه با نوسانات قیمت و

---

<sup>1</sup> Leading

<sup>2</sup> Lagging

اندیکاتورهای دنباله‌رو معمولاً با تأخیر، پس از حرکت قیمت و جابجایی بازار، هشدار و پیش‌بینی لازم را اعلام می‌کنند. به طور کلی اندیکاتورها در بازارهای مالی برای سه هدف استفاده می‌شوند:

۱- **هشدار:** اندیکاتورها در برخی مواقع و بر اساس شرایط، قبل از تغییر روند یا هم‌زمان با آن، علائم بازگشت روند را نمایش می‌دهند. پس یکی از مهم‌ترین کاربردهای اندیکاتور، اعلام هشدارهای مناسب تغییر روند و جهت حرکتی قیمت است.

۲- **پیش‌بینی:** یکی دیگر از موارد استفاده از اندیکاتورها، پیش‌بینی قیمت مناسب برای ورود به بازار است.

۳- **تایید:** مهم‌ترین استفاده‌ی اندیکاتورها، گرفتن تایید از تشخیص درست روند قیمتی است. به عنوان مثال این روش معمولاً زمانی مورد استفاده قرار می‌گیرد که تحلیل‌گر بر اساس داده‌های تکنیکالی یا بنیادی، جهت و قیمت ورودی مناسب در بازار را پیش‌بینی کرده و از اندیکاتور برای تایید گرفتن استفاده می‌کند.

## ۲,۱,۲ مدل ARIMA

یک روش معروف در مدل سازی سری‌های زمانی، در نظر گرفتن تکنیک‌های کلاسیک مانند استفاده از مدل ARIMA است. این مدل در پیش‌بینی داده‌های سری زمانی مانند پیش‌بینی آب و هوا، فروش برق، نرخ بیکاری و دیگر مسائل سری زمانی، مورد استفاده قرار گرفته است. برای استفاده از این مدل، باید یک شرط اساسی در داده‌های ما برقرار باشد، در حقیقت داده‌های مسئله باید ایستا<sup>1</sup> باشند.

---

<sup>1</sup> Stationary

مدل ARIMA به صورت گسترده ای در پیش بینی شده داده های ایستا مورد استفاده قرار می گیرد. در سال های اخیر در مورد تأثیر استفاده از این مدل برای پیش بینی قیمت بیت کوین، مطالعات و بررسی های زیادی انجام شده است. در مقاله ی [10] مشاهده می شود که مدل ARIMA برای مجموعه داده های جمع آوری شده ی در آن پژوهش، قابل پیاده سازی نیست. دلیل آن هم این است که داده ها خاصیت ایستایی را نداشتند و پس از تلاش برای ایستا کردن آن نیز، این امر تحقق نیافته است. در مقاله ی دیگری [2] از این مدل و مدل های دیگری مانند Logistic Regression و Random Forest برای پیش بینی قیمت بیت کوین استفاده کرده است و از این مدل ها برای انجام معامله و دریافت سود استفاده کرده است. در نهایت مشاهده شده است که مدل ARIMA به نسبت سایر مدل ها، سود کمتری را ایجاد کرده است. در مقاله ی دیگری [11] نیز از یک مدل ARIMA برای مقایسه با مدل یادگیری عمیق LSTM و RNN استاندارد، استفاده کرده است و در نهایت مشاهده کرده است که مدل ARIMA به نسبت دقت بسیار پایینی دارد.

## 2.2 مدل های یادگیری ماشین پیچیده

مدل ARIMA یکی از ساده ترین مدل های یادگیری ماشین بود که به دلیل نوسانات شدید قیمتی در بیت کوین، توانایی مدل کردن و پیش بینی قیمت را ندارد. امروزه استفاده از مدل های شبکه ی عصبی در پیش بینی سری زمانی بسیار محبوب هستند [14] و برخی مطالعات از ترکیب این مدل ها با اندیکاتورهای بهره برده اند و نتایج مطلوبی رسیده اند [5,12].

## ۱,۲,۲ مدل SVR

یکی دیگر از مدل های Regression که برای این امر مورد مطالعه قرار گرفته است، مدل SVR<sup>1</sup> می باشد. این مدل، اقتباس شده از مدل SVM<sup>2</sup> است که برای اولین بار توسط ولادیمیر وپنیک<sup>3</sup> و تیم تحقیقاتی اش در سال ۱۹۹۲ شناسایی شد و به جای متغیرهای کتگوریکال دارای متغیرها و ویژگی های عددی است. یک مزیت عمده استفاده از SVR این است که یک تکنیک غیر پارامتری<sup>4</sup> است. برخلاف مدل رگرسیون خطی ساده، که نتایج آن به مفروضات گاوس مارکوف بستگی دارد، مدل خروجی از SVR به توزیع متغیرهای وابسته و مستقل زمینه ای بستگی ندارد. در عوض روش SVR به توابع هسته بستگی دارد. یکی از تفاوت های مدل SVR با بیشتر مدل های رگرسیون خطی، این است که در مدل های رگرسیون خطی، هدف اصلی، به حداقل رساندن مجموع مربع خطاها است، اما در این مدل یک حداکثر حاشیه ی خطا تعیین می شود که باید خطا از این مقدار که به Epsilone معروف است، کمتر باشد. ایده ی حداکثر حاشیه اجازه می دهد تا SVR را به عنوان یک مسئله بهینه سازی در نظر بگیریم. این مدل رگرسیون همچنین با استفاده از پارامتر هزینه<sup>5</sup> میتواند از overfitting جلوگیری کند. SVR یک تکنیک مفید است که از نظر توزیع متغیرهای اساسی، رابطه بین متغیرهای مستقل و وابسته

---

<sup>1</sup> Support Vector Regression

<sup>2</sup> Support Vector Machine

<sup>3</sup> Vladimir Vapnik

<sup>4</sup> non-parametric

<sup>5</sup> Cost Parameter

و کنترل مدت مجازات، انعطاف پذیری بالایی را در اختیار استفاده کننده قرار می‌دهد. معروفترین تابع‌های هسته‌ای که در این مدل استفاده می‌شود،  $1RBF$  و Poly است. در یک مسئله غیر خطی، از تابع هسته می‌توان برای ارائه ابعاد اضافی به داده‌های خام و تبدیل آنها به یک مسئله خطی در فضای با بعد بیشتر استفاده کرد. نتایج این مدل قابل مقایسه و اغلب برتر از نتایج به‌دست آمده توسط دیگر الگوریتم‌های یادگیری، مانند شبکه‌های عصبی مصنوعی است [6]. در مقاله‌ای با آموزش این مدل با داده‌های یک روزه و ده روزه، دقت مدل SVR بهتر از مدل‌های دیگری مانند LSTM، WaveNet و Random Forest بود [3].

## ۲,۲,۲ مدل‌های $RNN^2$

یکی از مدل‌هایی که در پیش‌بینی سری‌های زمانی مورد استفاده قرار می‌گیرد، مدل شبکه عصبی مکرر (RNN) است. RNN ابتدا توسط Elman توسعه یافت. ساختار RNN مشابه MLP است، با این تفاوت که سیگنال‌ها می‌توانند هم به جلو و هم به‌صورت مکرر جریان یابند و برای تسهیل این امر، لایه دیگری به نام لایه زمینه<sup>3</sup> اضافه می‌شود. علاوه بر انتقال ورودی بین لایه‌ها، خروجی هر لایه به لایه context داده می‌شود تا با ورودی بعدی در لایه بعدی تغذیه شود. در این context، وضعیت در هر مرحله زمانی بازنویسی می‌شود. این مزیت به شبکه اجازه می

---

<sup>1</sup> Radius Basis Function

<sup>2</sup> Recurrent Neural Network

<sup>3</sup> Context Layer

دهد تا به جای اختصاص وزن ها به طور ثابت به گره ها (در MLP وزن ها در طول زمان ثابت می ماند) ، این وزن ها در طول زمان تغییر یابند و با دریافت فیدبک ، وزن ها اصلاح شوند. این منجر به ایجاد یک شبکه پویا می شود.

مدل RNN استاندارد اگر چه مشکل یادگیری به صورت زمانی را حل می کند و وزن ها با توجه به ارور به عقب منتشر شده آپدیت می شوند، اما همچنان مشکل ناپدید شدن گرادیان (Vanishing Gradient) را دارد. به این معنی که در هنگام آپدیت شدن وزن ها و به عقب منتشر شدن ارور، تغییر زیادی در وزن ها ایجاد نمی شود. مدل RNN از لحاظ تئوری قادر به یادگیری و مدیریت وابستگی های طولانی مدت است، اما در عمل به دلیل مشکل Vanishing Gradient این امر تحقق نمی یابد. بعد از مدل RNN استاندارد، مدل های LSTM و GRU با ساختار مشابه اما با تفاوت هایی در واحدها ایجاد شدند تا مشکل Vanishing Gradient را حل کنند.

## ۳,۲,۲ مدل LSTM

این مدل توسط Hochreiter و تیم اش توسعه یافته است تا مشکل vanishing gradient در مدل RNN را برطرف کند. این مدل یک نوع به خصوص از مدل های RNN است که قادر به یادگیری وابستگی های طولانی مدت است. این مدل در مسائل با دامنه های مختلف مورد استفاده قرار گرفته است و یکی از کاربردهای استفاده ی آن در پیش بینی سری های زمانی است. این مدل به نحوی طراحی شده است تا از مشکل وابستگی های طولانی مدت، جلوگیری کند. همه ی مدل های RNN دارای فرم زنجیره ای از واحدهای شبکه ی عصبی هستند. در LSTM برخلاف مدل RNN استاندارد، به جای استفاده از یک لایه ی شبکه ی مصنوعی در هر واحد، از چهار لایه ی شبکه ی عصبی استفاده شده است. LSTM این

توانایی را دارد تا اطلاعاتی را از وضعیت واحد<sup>1</sup> حذف و یا به آن اضافه کند. این امر توسط گیت‌های موجود در واحدها محقق می‌شود. هر واحد LSTM دارای سه نوع گیت است. گیت فراموشی مشخص می‌کند که چه اطلاعاتی از وضعیت پیشین واحد، حذف شوند و دیگر در وضعیت فعلی تکرار نشوند. گیت ورودی مشخص می‌کند که چه اطلاعات جدید به وضعیت فعلی اضافه شود. در نهایت گیت خروجی اطلاعاتی را از وضعیت جدید واحد، به صورت فیلتر شده به عنوان خروجی واحد باز می‌گرداند. به دلیل وجود چنین ساختاری، این مدل می‌تواند وابستگی‌های طولانی مدت را حفظ و یا آنها را حذف کند. این مدل در پیش بینی سری‌های زمانی بسیار محبوب است و معمولاً این مدل دقت بالاتری نسبت به سایر مدل‌های معمول در پیش بینی سری زمانی ارائه می‌دهد [9, 10]. در مقاله‌ی [11] مشاهده می‌شود که این مدل در پیش بینی قیمت بیت کوین از مدل‌های RNN استاندارد و مدل ARIMA عملکرد بهتری داشته است میزان دقت بالاتری دارد.

## ۴,۲,۲ مدل GRU

این مدل نیز از دسته مدل‌های RNN است. مدل GRU در مقایسه با مدل LSTM تعداد گیت‌های کمتری در هر واحد دارد و تنها دارای دو گیت ریست و آپدیت است. این امر باعث می‌شود که پیچیدگی کمتری نسبت به مدل LSTM داشته باشد. زمانی که دیتاست مسئله کوچک باشد، معمولاً این مدل نسبت به مدل LSTM ترجیح داده می‌شود. در مقاله‌ی [7] عملکرد این مدل با مدل LSTM و دو مدل رگرسیون دیگر سنجیده شده است و در نتایج این

---

<sup>1</sup> Cell State

تحقیق مشاهده می‌شود که مدل GRU میزان خطای MSE کمتری نسبت به سایر مدل‌ها دارد.



## فصل 3

### روش تحقیق

در این بخش به شرح کلی روش استفاده شده برای ایجاد سیستم پیش بینی قیمت بیت کوین میپردازیم. ایجاد این سیستم میتواند شامل مسائلی مانند پیش پردازش، انتخاب مدل های کارآمد، آموزش مدل ها و ارزیابی عملکرد مدل ها باشد. عمده ی فعالیت ما در این پروژه مطالعه و یافتن اندیکاتورهای مناسب برای مدل های هوش مصنوعی مورد نظر است. پس از انتخاب این ویژگی ها و ساخت مدل ها، برای ارزیابی عملکرد مدل ها در پیش بینی قیمت، استراتژی های خرید و فروش تعیین می کنیم و بر اساس این استراتژی ها و خروجی مدل ها به معامله می پردازیم.

#### 1.3 تعریف مسئله

در این بخش به شرح سیستمی که قصد ایجادش را داریم، می پردازیم.

### ۱,۱,۳ ساخت مدل پیش بینی قیمت بیت کوین

در این پژوهش با استفاده از مدل‌های LSTM و GRU تلاش کردیم تا مدل‌هایی آموزش دهیم که با دریافت داده‌های بیت کوین (قیمت، حجم معاملات، تعداد معاملات و اندیکاتورهای مورد نظر) در تایم فریم فعلی، قیمت بسته شدن<sup>1</sup> بیت کوین در تایم فریم بعدی را پیش بینی کند.

### ۲,۱,۳ ساخت سیستم معامله خودکار

به منظور بررسی کارایی مدل‌های ساخته شده، یک سیستم معامله‌ی خودکار ایجاد کرده ایم تا با دریافت قیمت فعلی و قیمت پیش بینی شده توسط مدل‌ها، تصمیم به خرید و فروش بگیرد. برای این تصمیم گیری، استراتژی خرید و فروش تعریف کردیم و با در نظر گرفتن هزینه‌های معامله<sup>2</sup>، معاملات را ایجاد کرده ایم.

### 2.3 فرآیند جمع آوری داده‌ها

قدم اول برای ساخت سیستم پیش بینی قیمت بیت کوین، جمع آوری داده‌های قیمت بیت کوین از یک منبع معتبر است.

---

<sup>1</sup> Close price

<sup>2</sup> Transaction cost

## ۱,۲,۳ انتخاب منبع داده<sup>۱</sup>

بیت کوین به عنوان دارایی<sup>۲</sup> در بسیاری از صرافی‌های آنلاین خرید و فروش می‌شود. صرافی‌های مختلف به دلیل امکاناتی که ارائه می‌کنند، تعداد معامله کنندگان و حجم معاملات متفاوتی دارند. برخی مقالات داده‌های خود را از چند صرافی مختلف جمع آوری کرده‌اند و در نهایت از تلفیق آنها در مدل‌های خود استفاده کرده‌اند، این امر باعث می‌شود که اطلاعات دقیقی از وضعیت بازار داشته باشیم. اما در برخی دیگر از مقالات، داده‌ها از تنها یک صرافی جمع آوری شده است. در این پژوهش به دلیل اینکه قصد داریم تا از این سیستم پیش بینی برای خرید و فروش بیت کوین استفاده کنیم نیاز است تا اطلاعات قیمت از همان صرافی که قصد معامله در آن را داریم، جمع آوری شده باشد. از ویژگی‌های یک منبع خوب برای جمع آوری داده‌ها، حجم معاملات روزانه‌ی آن صرافی است. هرچه حجم معاملات یک صرافی بیشتر باشد، قیمت‌ها در آن به روزتر و معتبرتر است. طبق اطلاعات منتشر شده در یک سایت معتبر اخبار رمز ارزها<sup>۳</sup> در حال حاضر صرافی بایننس بیشترین حجم معاملات روزانه را دارد. این صرافی به دلیل پشتیبانی رمز ارزهای متنوع و ارائه‌ی ویژگی‌های منحصر به فرد برای معامله ی بیت کوین، مانند ایجاد موقعیت فروش<sup>۴</sup> و امکان زدن اهرم روی معاملات، بسیار محبوب است. یکی دیگر از مزایای این صرافی، داشتن api هایی با امکان فراخوانی با فرکانس بالا،

---

<sup>۱</sup> Data Source

<sup>۲</sup> asset

<sup>۳</sup> <https://coinmarketcap.com/>

<sup>۴</sup> Sell Position

برای اطلاعات قیمت لحظه‌ای و تاریخچه‌ای رمز ارزها است. در این پژوهش ما از api مربوط به kline/candlestick data استفاده می‌کنیم. این api با دریافت interval<sup>1</sup> و زمان شروع و پایان برای دریافت قیمت‌های دوره‌ی مدت نظر، به ازای هر interval موجود در این بازه‌ی زمانی، یک آرایه شامل داده‌های OHLC، حجم بیت کوین معامله شده در آن بازه، حجم ارز پایه‌ی معامله شده در آن بازه، و تعداد معاملات و اطلاعاتی دیگر به ما ارائه می‌کند. در این پژوهش ارز پایه را دلار در نظر گرفته‌ایم و interval های پانزده دقیقه‌ای و یک روزه را برای داده‌های تاریخی در نظر گرفته‌ایم.

مجموعه داده‌های پانزده دقیقه‌ای: این داده از تاریخ ۲۰۲۱/۰۳/۱۸ تا تاریخ ۲۰۲۱/۰۲/۰۹ از صرافی بایننس جمع‌آوری شده است که مجموعاً دارای ۱۶۰۵۰ فاصله‌ی زمانی است. این داده‌ها در آینده برای آموزش مدل‌های LSTM و GRU و SVR مورد استفاده قرار گرفته‌اند.

مجموعه داده‌های روزانه: این داده‌ها نیز از تاریخ ۲۰۲۱/۰۳/۱۸ تا تاریخ ۲۰۲۱/۰۲/۰۹ جمع‌آوری شده‌اند که مجموعه دارای ۱۶۸ فاصله‌ی زمانی است. این داده‌ها نیز برای آموزش مدل‌های LSTM و GRU مورد استفاده قرار گرفته‌اند.

---

فاصله‌ی زمانی<sup>1</sup>

## ۲,۲,۳ ذخیره‌ی داده‌های جمع آوری شده

پس از دریافت داده‌های مورد نظر، در مرحله‌ی بعد باید آن را در یک ساختمان داده ذخیره کنیم، برای این منظور از ساختمان داده‌ی MySQL استفاده کرده‌ایم که سرعت دسترسی به داده‌های مطلوبی دارد و به‌صورت بهینه داده‌ها را ذخیره می‌کند.

## ۳,۳ انتخاب ویژگی‌های مدل

در مرحله‌ی بعد باید ویژگی‌های مورد نظر خود را از داده‌های جمع آوری شده استخراج کنیم. ویژگی‌های مورد نظر به‌صورت زیر است:

- داده‌های OHLC: این داده‌ها که قیمت بیت کوین در ابتدا و انتهای بازه و همچنین بیشترین و کمترین قیمت در این بازه را مشخص می‌کنند، علاوه بر مشخص کردن قیمت، بیان‌کننده‌ی میزان نوسانات نیز هستند. بنابراین هر چهار داده را به‌عنوان ویژگی انتخاب کرده‌ایم.
- داده‌ای حجمی: این داده‌ها که مشخص‌کننده‌ی حجم بیت کوین و حجم دلار معامله شده هستند، برای پیش‌بینی قیمت بیت کوین بسیار مهم هستند. زیرا هرچه حجم معاملات بیشتر باشد، یعنی بازار فعال‌تر است و در نتیجه با توجه به اینکه خریداران قالب هستند و یا فروشندگان، ممکن است افزایش و یا کاهش قیمت چشم‌گیری رخ دهد.
- تعداد معاملات انجام شده: تعداد معاملات انجام شده نیز بر روی قیمت بیت کوین تأثیر است. زیرا اگر در دو تایم فریم با حجم معاملات یکسان، یکی از آنها تعداد معاملات کمتری داشته باشد، به این معناست که در آن زمان

معاملات بزرگ تری انجام شده است. زمانی که معاملات بزرگ تر باشد، احتمال افزایش قیمت بیشتر است.

- اندیکاتورها: همانطور که پیشتر گفته شد، استفاده از اندیکاتورها در معامله گری بسیار رایج است. اندیکاتورها اطلاعاتی بیشتر از مواردی که پیشتر اشاره شد نمی‌دهند و در حقیقت طبق فرمول‌های ریاضی از اطلاعات داده‌های OHLC و حجم معاملات به دست می‌آیند. اما نکته‌ای که باعث می‌شود آنها را به عنوان ویژگی‌های جدید به مدل‌های خود اضافه کنیم این است که مدل‌ها ممکن است در جریان آموزش به این روابط نرسند، بنابراین داشتن آنها به عنوان ویژگی ورودی باعث می‌شود که حتماً در آموزش به مقدار اندیکاتورها توجه شود.

### ۱,۳,۳ انتخاب اندیکاتورها

همانطور که پیشتر اشاره شد، اندیکاتورها، ابزارهایی هستند که دید دقیق تری از وضعیت قیمت ارز، روند قیمتی، اشباع‌ها می‌دهند. در این پژوهش به بررسی تعدادی از اندیکاتورها پرداختیم و تعدادی از آنها که در بازار بیت کوین کارایی بالایی دارند را انتخاب و به عنوان ویژگی مدل‌ها اضافه کردیم. در این پژوهش از کتابخانه TA-Lib برای ساخت اندیکاتورها استفاده کرده‌ایم. در ادامه اندیکاتورهای انتخاب شده را معرفی می‌کنیم.

#### اندیکاتور جهت گیری متوسط (ADX)

این اندیکاتور از دسته اندیکاتورهای logging است و قدرت روند را نشان می‌دهد. انجام معاملات در زمانی که روند فعلی قدرت زیادی دارد، پتانسیل دریافت سود را افزایش می‌دهد. از

این اندیکاتور برای یافتن زمان افزایش قدرت روند استفاده می‌شود. فرمول اندیکاتور ADX بر اساس میانگین متحرک قیمت در یک بازه‌ی زمانی خاص است و معمولاً از ۱۴ بازه‌ی زمانی برای این اندیکاتور استفاده می‌شود. این اندیکاتور به صورت یک خط و با محدوده‌ای بین ۰ تا ۱۰۰ نمایش داده می‌شود. همچنین جهت حرکت ADX روی قدرت روند تأثیر است و زمانی که این اندیکاتور صعودی است، قدرت روند نیز در حال افزایش است. طبق مشاهدات انجام شده زمانی که میزان این اندیکاتور از ۳۰ بالاتر باشد، نشان دهنده‌ی یک روند قوی و اگر از ۴۰ بالاتر باشد، نشان دهنده‌ی یک روند بسیار قوی است.

این اندیکاتور بدون جهت است، به این معنی که نمی‌تواند روند فعلی قیمت (صعودی یا نزولی بودن) را تشخیص دهد و تنها می‌تواند قدرت روند را به ما نشان دهد. به همین دلیل معمولاً در کنار این اندیکاتور دو اندیکاتور دیگر که جهت قیمت را مشخص می‌کنند نیز استفاده می‌شود. این دو اندیکاتور که به +DMI و -DMI معروف هستند، نزولی و یا صعودی بدن بازار را نشان می‌دهند.

زمانی که +DMI بالاتر از -DMI قرار دارد، جهت قیمت صعودی است و بازار تحت تسلط خریداران است. و زمانی که -DMI بالاتر باشد، یعنی بازار نزولی است. در این پژوهش نیز ما هر سه اندیکاتور را در کنار هم با دوره زمانی<sup>1</sup> برابر با ۱۴ به عنوان ویژگی‌های مدل‌ها انتخاب کرده ایم.

### اندیکاتور میانگین متحرک نمایی (EMA)

---

<sup>1</sup> timeperiod

این اندیکاتور از دسته اندیکاتورهای میانگین متحرک وزن دار است که وزن بیشتری را به داده‌های اخیر نسبت می‌دهد. این امر کمک می‌کند تا نسبت به میانگین متحرک ساده، تغییر جهت روند قیمت را زودتر متوجه شویم. معمولاً از چند میانگین متحرک نمایی با دوره‌ی زمانی متفاوت به صورت همزمان استفاده می‌شود. به عنوان مثال در این پژوهش ما از دو اندیکاتور میانگین متحرک نمایی با دوره‌های زمانی ۱۲ و ۲۶ استفاده کرده ایم. مزیت این کار این است که اندیکاتور با دوره زمانی طولانی‌تر، به داده‌های قدیمی‌تر نیز توجه می‌کند و برای آنها نیز وزنی در نظر می‌گیرد. حال اگر اندیکاتور با دوره زمانی کمتر بالاتر از اندیکاتور با دوره زمانی بیشتر قرار گیرد نشان دهنده‌ی این است که در دوره زمانی اخیر، قیمت افزایش داشته است و روند بازار صعودی است.

### اندیکاتور قدرت نسبی (RSI)

یک اندیکاتور حرکت<sup>1</sup> است که بزرگی تغییرات قیمت اخیر را برای ارزیابی شرایط خرید بیش از حد (overbought) و یا فروش بیش از حد (oversold) اندازه گیری می‌کند. زمانی که خرید بیش از حد اتفاق بیوفتد، به این معنی است که خرید اشباع شده است و به زودی بازار نزولی می‌شود. به صورت مشابه زمانی که فروش بیش از حد اتفاق بیفتد به این معنی است که ظرفیت بازار برای فروش تکمیل شده است و بازار صعود خواهد کرد. این اندیکاتور به عنوان نوسان ساز<sup>2</sup> مورد استفاده قرار می

---

<sup>1</sup> Momentum indicator

<sup>2</sup> oscillator



گیرد. به این معنی است که بین دو محور افقی نوسان می‌کند و میتواند مقداری بین ۰ تا ۱۰۰ داشته باشد. با مشاهده نمودارهای مربوط به اندیکاتور RSI برای بیت کوین، متوجه می‌شویم که زمانی که این اندیکاتور بالاتر از ۷۰ است، اشباع در خرید اتفاق افتاده است و زمانی که پایین‌تر از ۳۰ است، اشباع در فروش اتفاق افتاده است و قیمت افزایش خواهد یافت. این اندیکاتور توسط بسیاری از معامله‌گران بیت کوین مورد استفاده قرار می‌گیرد، زیرا میتواند تغییر روند را پیش‌بینی کند.

### اندیکاتور واگرایی / همگرایی میانگین متحرک (MACD)

این اندیکاتور نیز از دسته اندیکاتورهای حرکت است و روند بازار را پیش‌بینی می‌کند. همانطور که قابل پیش‌بینی است از اختلاف دو میانگین متحرک با دوره زمانی مختلف در آن استفاده می‌شود. همچنین از یک میانگین متحرک دیگر به عنوان خط سیگنال<sup>۱</sup> استفاده می‌شود که دوره زمانی کمتری نسبت به دو میانگین متحرک دیگر دارد. در این پژوهش ما از دو میانگین متحرک با دوره زمانی ۱۲ و ۲۶ برای خط MACD و یک میانگین متحرک با دوره زمانی ۹ برای خط سیگنال استفاده کرده‌ایم. زمانی که خط MACD، با خط سیگنال برخورد کند و به بالای آن برود، روند بازار صعودی پیش‌بینی می‌شود و زمانی که با آن برخورد کند و به سمت پایین بیاید، روند بازار نزولی پیش‌بینی خواهد شد. این اندیکاتور میتواند به روش‌های مختلفی تفسیر شود اما تشخیص همگرایی / واگرایی رایج‌ترین روش

---

<sup>1</sup> Signal line

استفاده از آن است. این اندیکاتور نیز از اندیکاتورهایی است که معامله گران بیت کوین علاقه‌ی زیادی به آن دارند و برای پیش‌بینی روند از آن در کنار اندیکاتورهای تشخیص اشباع، مانند RSI استفاده می‌شود. لازم به ذکر است که این اندیکاتور معمولاً دقت کافی ندارد و در بسیاری از موارد تغییر روندی را گزارش می‌کند اما در واقعیت تغییر روندی رخ نمی‌دهد.

### اندیکاتور قدرت نسبی تصادفی (Stochastic RSI)

این اندیکاتور در محدوده‌ی صفر تا یک نوسان می‌کند و با استفاده از فرمول نوسان ساز تصادفی بر روی مجموعه‌ای از مقادیر شاخص قدرت نسبی (RSI) به جای داده‌های قیمت استاندارد، ایجاد می‌شود. استفاده از فرمول Stochastic به همراه RSI به معامله گران نشان می‌دهد که مقدار RSI فعلی بیش از حد و یا کمتر از حد واقعی است. این اندیکاتور برای بهره بردن از مزیت هر دو اندیکاتور Stochastic و RSI به وجود آمده است تا اندیکاتور حساس‌تر ایجاد شود. در بیت کوین معمولاً زمانی که مقدار این اندیکاتور بالاتر ۰/۸ باشد، نشان دهنده‌ی خرید بیش از حد و نزول قیمت در آینده‌ی نزدیک است. همچنین زمانی که مقدار آن از ۰/۲ پایین‌تر بیاید نشان دهنده‌ی فروش بیش از حد و صعود قیمت در آینده نزدیک است. همانطور که پیش‌تر گفته شد این اندیکاتور حساسیت و نوسانات زیادی دارد. به همین دلیل هشدارهای اشباع داده شده توسط این اندیکاتور لزوماً به معنی تغییر روند نیست و صرفاً بیان‌کننده‌ی این است که به حداکثر RSI نسبت به RSI قبلی رسیده ایم. این اندیکاتور را موقتاً به ویژگی‌ها اضافه کردیم تا

بعد از پیش پردازش و بررسی ارزش ویژگی در مورد حذف و یا نگه داشتن آن تصمیم بگیریم.

### اندیکاتور بولینگر باند (Bollinger Bands)

این اندیکاتور از سه خط تشکیل شده است و به صورت گسترده ای توسط معامله گران مورد استفاده قرار می گیرد. خط میانه، یک نوع میانگین متحرک ساده با دوره زمانی ۲۰ است. دو خط بالایی و پایینی، هر دو به اندازه ی دو برابر انحراف معیار قیمت از خط میانه فاصله دارند. این اندیکاتور معمولاً برای تشخیص اشباع مورد استفاده قرار می گیرد. زمانی که قیمت بیت کوین به زیر باند پایینی نزول کند، نشان دهنده ی این است که شرایط فروش بیش از حد رخ داده است و قیمت به زودی افزایش پیدا می کند. همچنین به صورت معکوس، زمانی که قیمت به بالای باند بالایی صعود کند نشان دهنده ی این است که افزایش، بیش از ارزش واقعی قیمت بیت کوین است و قیمت به زودی کاهش پیدا می کند. این اندیکاتور در مشاهدات ما بسیار کارآمد بوده است.

### ۴/۳ فرآیند انتخاب مدل ها

در این پژوهش مدل های پیشرفته ی یادگیری عمیق LSTM و GRU و مدل SVR را به عنوان مدل های خود انتخاب کردیم. دلیل انتخاب LSTM و GRU این است که این مدل ها قادر به یادگیری وابستگی های طولانی مدت هستند و قصد داریم بررسی کنیم که کدام یک از این دو مدل، با توجه به دیتاست های ما مناسبتر است. در این میان مدل SVR را که دسته مدل های Support Vector Machin می باشد به عنوان baseline برای مقایسه با مدل های

پیش‌گرفته‌ی یادگیری عمیق انتخاب کرده‌ایم. این مدل نیز در بسیاری از تحقیقات حوزه‌ی پیش‌بینی سری زمانی مورد استفاده قرار گرفته است. در ادامه فرایند پیش‌پردازش و انتخاب hyperparameter ها و آموزش مدل‌ها با دیتاست‌های سیستم برای هر مدل را شرح می‌دهیم.

## ۵/۳ پیش‌پردازش داده‌ها

پس از جمع‌آوری داده‌ها و انتخاب اندیکاتورها و ساخت آنها از آن داده‌ها، به پیش‌پردازش داده‌های خام می‌پردازیم. گام‌های انجام شده برای پیش‌پردازش داده‌ها شامل موارد زیر است:

### ۱،۵،۳ مهندسی ویژگی‌ها<sup>۱</sup>

مهندسی ویژگی هنر استخراج الگوهای مفید از داده‌ها است تا مدل‌های یادگیری ماشینی بتوانند پیش‌بینی خود را آسان‌تر انجام دهند. می‌توان آن را یکی از مهمترین مهارت‌ها برای دستیابی به نتایج خوب برای کارهای پیش‌بینی در نظر گرفت. مهندسی ویژگی‌ها مهمترین بخش یک پروژه‌ی هوش مصنوعی است. این فرآیند در ساخت سیستم پیش‌بینی قیمت بیت‌کوین، نیازمند دانش در حوزه‌ی اقتصاد است. همانطور که پیش‌تر اشاره کردیم در اینجا ما اندیکاتورهایی را مطالعه و با پارامترهای مناسب به‌عنوان ویژگی مدل‌های خود انتخاب کردیم.

---

<sup>1</sup> Feature engineering

## ۲,۵,۳ ارزیابی ویژگی‌ها<sup>۱</sup>

پس از انتخاب ویژگی‌ها، این ویژگی‌ها باید ارزیابی شوند. دلیل آن هم این است که ما ویژگی‌های زیادی را به‌عنوان ورودی انتخاب کرده‌ایم، این امر باعث می‌شود که زمان آموزش به میزان قابل توجهی افزایش یابد. علاوه بر این، در مدل‌های یادگیری ماشین، اگر تعداد ویژگی‌ها بیشتر از حد مطلوب باشد، ممکن است به ویژگی‌هایی که ارزش زیادی ندارند، وزن زیادی داده شود و در نتیجه آموزش بخوبی صورت نگیرد و مدل دقت پایینی داشته باشد.

چندین روش ارزیابی ویژگی از جمله انتخاب مبتنی بر فیلتر<sup>۲</sup> و انتخاب مبتنی بر بسته بندی<sup>۳</sup> وجود دارد. انتخاب کننده‌های مبتنی بر فیلتر ویژگی‌ها را بر اساس یک خاصیت آماری ویژه از ویژگی فیلتر می‌کنند مانند همبستگی ویژگی‌ها. روش‌های مبتنی بر بسته بندی جستجوی ابتکاری راه حل‌های طبقه بندی کننده را انجام می‌دهد. لازم به ذکر است که داده‌های OHLC و حجم معاملات بدون ارزیابی مستقیماً به‌عنوان ویژگی ورودی انتخاب شده‌اند. دلیل آن هم این است که این ویژگی‌ها داده‌های اصلی برای پیش بینی قیمت بیت کوین هستند که به وضوح همگی آنها تأثیر زیادی روی قیمت آینده بیت کوین می‌گذارند. اما اندیکاتورهای داده‌هایی هستند که از طریق داده های OHLC به دست می‌آیند و ممکن است نیازی به آنها به‌عنوان ویژگی مستقل نداشته باشیم. در اینجا با استفاده از متد `mutual_info_regression` که یک روش انتخاب مبتنی بر فیلتر

---

<sup>۱</sup> Feature evaluation

<sup>۲</sup> Filter based selection

<sup>۳</sup> Wrapper based selection

است، همبستگی اندیکاتورها را بررسی کردیم و از این میان تعدادی از ویژگی‌ها که همبستگی بالایی داشتند، انتخاب کردیم. از سمت دیگر با استفاده از متد انتخاب ویژگی SelectKBest ده ویژگی را انتخاب کردیم. سپس ویژگی‌هایی که از هر دو روش انتخاب شده بودند به‌عنوان ویژگی ورودی به مدل خود اضافه کردیم.

### ۳,۵,۳ تمیز کردن داده‌ها<sup>1</sup>

بعد از انتخاب ویژگی‌هایی که قصد داریم به‌عنوان ورودی به مدل خود بدهیم، باید دیتاست خود را تمیز کنیم. در اینجا به‌دلیل استفاده از اندیکاتورها با دوره زمانی مختلف، ممکن است تعدادی از دوره‌های زمانی اول دیتاست، دارای مقدار Nan باشند، به همین دلیل باید این مقادیر را با صفر جایگزین کنیم تا در طول آموزش مدل مشکلی ایجاد نشود.

### ۴,۵,۳ نرمال سازی داده‌ها

در مدل‌های هوش مصنوعی، در صورتی که یک ویژگی مقادیر بالاتری نسبت به سایر ویژگی‌ها داشته باشد، ممکن است باعث شود تأثیر این ویژگی روی خروجی به‌طور نادرستی بیشتر از ویژگی‌های دیگر باشد. برای حل این مشکل باید داده‌های خود را نرمال سازی کنیم. در این پروژه ما از Min-Max scaler برای این موضوع استفاده کرده‌ایم. MinMaxScaler از کتابخانه‌ی

---

<sup>1</sup> Data cleaning

scikit-learn میتواند از معامله ۱ استفاده کند تا داده‌ها را نرمال کند:

(1-3)

$$x_{sc} = \frac{x - \min(x)}{\max(x) - \min(x)}$$

که در آن  $x$  آرایه‌ای از مجموعه داده‌های یک ویژگی می‌باشد.

### ۵,۵,۳ جداسازی داده‌های تست و آموزش

در این مرحله دیتاست را به دو دسته داده‌ی آموزش و تست تقسیم می‌کنیم. به این منظور برای دیتاست روزانه، ۸۵ درصد ابتدایی داده‌ها را داده‌های آموزش و مابقی را داده‌های تست در نظر می‌گیریم. برای دیتاست با تایم فریم ۱۵ دقیقه‌ای، به دلیل بیشتر بودن داده‌ها، ۷۰ درصد ابتدای را داده‌های آموزش و بقیه‌ی داده‌ها را داده‌های تست در نظر می‌گیریم.

پس از جداسازی داده‌های آموزش، باید مدل‌های خود را با پارامترهای مناسب ایجاد کنیم و سپس مدل‌ها را با این داده‌ها آموزش دهیم.

### ۶,۳ جزئیات پیاده سازی و آموزش مدل‌ها

در این بخش به شرح ساختار مدل‌هایی که روی آنها عملیات آموزش انجام می‌شود، می‌پردازیم.

## ۱,۶,۳ مدل LSTM

مدل LSTM اولین مدلی بود که برای پژوهش خود برگزیدیم. دو مدل LSTM با دیتاست های روزانه و ۱۵ دقیقه ای ایجاد کرده ایم که هر کدام از آنها با پارامترهای مختلفی تنظیم شده اند. در ادامه ساختار مدل ها را توضیح می دهیم:

### ساختار مدل

مدل LSTM از پارامترهایی نظیر تابع فعال سازی<sup>۱</sup>، تابع از دست دادن<sup>۲</sup>، بهینه ساز<sup>۳</sup>، تعداد لایه ها، واحدهای موجود در هر لایه، نرخ حذف<sup>۴</sup> در لایه ها، تعداد دوره های آموزش، سائز دسته ها<sup>۵</sup> تشکیل شده است. که مقادیر آنها برای هر دو مدل در جداول ۱ و ۲ نمایش داده شده است. برای LSTM با دیتاست روزانه (جدول ۱)، یک لایه ی hidden state در نظر گرفته ایم. در لایه ی ورودی ۷۰۰ واحد و در لایه ی پنهان ۳۰۰ واحد LSTM در نظر گرفته ایم. به عنوان تابع loss از mean\_absolute\_error استفاده کرده ایم. فرمول این خطا به صورت زیر محاسبه می شود:

(2-3)

$$MAE = \sum_{i=1}^n \frac{|y_i - x_i|}{n}$$

---

<sup>1</sup> Activation function

<sup>2</sup> Loss function

<sup>3</sup> optimizer

<sup>4</sup> dropout

<sup>5</sup> Batch size



که در این فرمول  $y_i$  برابر با مقدار پیش بینی شده و  $x_i$  برابر با مقدار واقعی است و  $n$  تعداد کل داده های آموزش است. لازم به ذکر است که در این مدل و مدل GRU پنجره ی زمانی را برابر با یک در نظر گرفته ایم. به این صورت که در ورودی ها تنها اطلاعات قیمت تایم فریم قبلی را می دهیم.

نام پارامتر	مقدار
تعداد لایه ها	۳ لایه ( ۱ لایه ی hidden state)
تعداد واحدهای موجود در هر لایه	[۷۰۰ - ۳۰۰ - ۱]
نرخ حذف واحد در هر لایه	[۰,۲ - ۰,۲ - ۰]
تعداد دوره های آموزش	۴۰۰
تعداد دسته ها	۷۲
بهینه ساز	adam
تابع loss	mean_absolute_error

جدول ۱/۳ پارامترهای تنظیم شده برای مدل LSTM با تایم فریم روزانه

برای LSTM با دیتاست ۱۵ دقیقه ای (جدول ۲) نیز از یک لایه ی hidden state استفاده کرده ایم. اما برای آموزش آن از تعداد دوره های کمتری استفاده کرده ایم. دلیل آن این است که

این مدل دیتاست بزرگ تری دارد و میتواند با تعداد دوره‌های آموزش بالا، دچار overfitting شود. پارامترهای دیگر مشابه مدل قبلی می‌باشد.

نام پارامتر	مقدار
تعداد لایه‌ها	۳ لایه ( ۱ لایه (hidden state)
تعداد واحدهای موجود در هر لایه	[۱ - ۵۰ - ۱۰۰]
نرخ حذف واحد در هر لایه	[۰ - ۰٫۲ - ۰٫۲]
تعداد دوره‌های آموزش	۱۰۰
تعداد دسته‌ها	۷۲
بهینه ساز	adam
تابع loss	mean_absolute_error

جدول ۲/۳ پارامترهای تنظیم شده برای مدل LSTM با تایم فریم ۱۵ دقیقه‌ای

### ۲/۴/۳ مدل GRU

برای این مدل نیز از پارامترهایی مشابه پارامترهای مدل LSTM تنظیم کرده‌ایم، استفاده کردیم. مدل GRU با دیتاست روزانه مشابه LSTM دارای ۱ لایه hidden state می‌باشد، اما تعداد واحدهای به عددهای کمتری ( ۲۰۰ واحد در لایه ورودی

و ۵۰ واحد در لایه‌ی پنهان) تنظیم شده است. زیرا همانطور که پیش‌تر بیان شد، مدل GRU ساختار ساده تری نسبت به مدل LSTM دارد و این مدل برای دیتاست روزانه که کوچکتر است، با تعداد نوروں‌های کمتر و پیچیدگی کمتر نسبت به LSTM آموزش داده می‌شود.

نام پارامتر	مقدار
تعداد لایه‌ها	۳ لایه ( ۱ لایه ی (hidden state
تعداد واحدهای موجود در هر لایه	[۱ - ۵۰ - ۲۰۰]
نرخ حذف واحد در هر لایه	[۰ - ۰٫۲ - ۰٫۲]
تعداد دوره‌های آموزش	۴۰۰
تعداد دسته‌ها	۷۲
بهینه ساز	adam
تابع loss	mean_absolute_error

جدول ۳/۳ پارامترهای تنظیم شده برای مدل GRU با تایم فریم روزانه

مدل GRU با دیتاست ۱۵ دقیقه‌ای، پارامترهایی کاملاً مشابه با مدل LSTM با دیتاست ۱۵ دقیقه‌ای دارد (جدول ۳)

نام پارامتر	مقدار
تعداد لایه‌ها	۳ لایه ( ۱ لایه (hidden state
تعداد واحدهای موجود در هر لایه	[۱ - ۵۰ - ۱۰۰]
نرخ حذف واحد در هر لایه	[۰ - ۰٫۲ - ۰٫۲]
تعداد دوره‌های آموزش	۱۰۰
تعداد دسته‌ها	۷۲
بهینه ساز	adam
تابع loss	mean_absolute_error

جدول ۴/۳ پارامترهای تنظیم شده برای مدل GRU با تایم فریم روزانه

### ۳/۶/۳ تعریف baseline

مدل‌های یادگیری عمیق بیان شده، تقریباً ساختار مشابهی دارند و هر دو از نوع مدل‌های RNN هستند. برای ارزیابی دقت این مدل‌ها، از دو baseline استفاده می‌کنیم و دقت آنها را با دو مدل دیگر مقایسه می‌کنیم. اولین baseline برای مقایسه با مدل‌های یادگیری عمیق، مدل SVR است. همچنین همانطور که پیش از این در بخش اندیکاتورهای گفته شد، اندیکاتور میانگین متحرک، برای پیش بینی قیمت بیت کوین،

اندیکاتور بسیار محبوبی است. در اینجا از اندیکاتور میانگین متحرک با دوره‌ی زمانی برابر با ۱۲ به عنوان baseline استفاده می‌کنیم.

برای پیش‌پردازش مدل SVR، مراحل پیش‌پردازشی که برای مدل‌های LSTM و GRU انجام داده بودیم شامل اضافه کردن اندیکاتورهای به عنوان ویژگی، تمیز کردن دیتاست، نرمال سازی داده‌ها و در نهایت تقسیم به داده‌های تست و آموزش را انجام می‌دهیم. ویژگی‌ها و ساختار مدل SVR برای هر دو دیتاست، یکسان در نظر گرفته شده است. هسته‌ای که در الگوریتم در نظر گرفته شده است poly می‌باشد. به همین دلیل پارامتر درجه را نیز باید تنظیم می‌کردیم. درجه این هسته‌ی چند جمله‌ای را برابر با 1 در نظر گرفته‌ایم. پارامتر C را برابر با ۰/۱ در نظر گرفته‌ایم. بقیه‌ی پارامترها را با مقدار دیفالت خودشان گرفته‌ایم.

پس از SVR، مدل میانگین متحرک را برای هر دو دیتاست ایجاد می‌کنیم. این مدل تنها دارای یک ویژگی قیمت بسته شدن است و نیازی به ویژگی‌های دیگر ندارد. همچنین این مدل نیاز به پیش‌پردازشی ندارد و تنها باید دیتاست را مشابه مدل‌های قبلی، به دو دسته‌ی داده‌های تست و آموزش تقسیم می‌کنیم. ضریب این تقسیم بندی مشابه مدل‌های قبلی است زیرا می‌خواهیم با پیش‌بینی آن مدل‌ها مقایسه کنیم. فرمول محاسبه‌ی پیش‌بینی برای این مدل برابر است با:

(3-3)

$$y_i = \frac{\sum_{j=1}^{12} x_{i-j}}{12}$$

که در این معادله،  $y_i$ ، قیمت پیش بینی شده برای تایم فریم  $i$  ام است و  $x_i$  قیمت واقعی بیت کوین در تایم فریم  $i$  ام است.

## ۷،۳ ارزیابی مدل‌ها

برای ارزیابی مدل‌ها، از داده‌های تست استفاده کردیم و مقدار پیش بینی شده را با مقدار واقعی آن مقایسه کردیم. نتایج به دست آمده در فصل نتایج قابل رؤیت هستند.

## ۱،۷،۳ پیاده سازی سیستم معامله گری خودکار

### انواع استراتژی‌ها

برای معامله در بازار رمز ارز دو روش محبوب وجود دارد.

۱- خرید و نگهداری<sup>۱</sup>: در این روش فرد در زمانی که بازار تحت تسلط خریداران است و قیمت روند صعودی دارد، ارز مورد نظر خود را خریداری می‌کند و برای بازه‌ی زمانی طولانی آن را نگه داری می‌کند و با نوسانات کوچک، معامله‌ای انجام نمی‌دهد. در نهایت زمانی که سود مطلوب خود را دریافت کرد، رمز ارزهای خود را می‌فروشد و از بازار خارج می‌شود. این روش برای افرادی مناسب است که می‌توانند سرمایه خود را برای بلند مدت در صرافی را نگه دارند. از مزیت‌های این روش این است که ریسک ضرر در آن کمتر است و امکان سود دهی بسیار بالا است.

---

<sup>1</sup> Buy and Hold

۲- معامله گری فعالانه<sup>1</sup> : در این روش فرد همواره در حال رصد بازار است و زمانی که روند قیمت نزولی است و یا اشباع در خرید رخ داده است، رمز ارزهای خود را میفروشد و از طرف دیگر، اگر روند قیمت صعودی باشد، ارز پایه خود را به رمز ارز تبدیل می‌کند.

در این پژوهش برای ارزیابی کارایی سیستم پیش بینی قیمت ایجاد شده، یک سیستم معامله گری فعالانه ایجاد کردیم و با روش خرید و نگهداری مقایسه کردیم. به این منظور باید یک واحد تصمیم گیری برای خرید و فروش داشته باشیم. به این صورت که این واحد، خروجی سیستم پیش بینی برای قیمت در تایم فریم بعدی و قیمت واقعی حال را دریافت می‌کند و با استفاده از استراتژی‌های خرید و فروش، سیگنال‌های خرید، فروش و یا خنثی باز می‌گرداند. در ادامه استراتژی مورد استفاده برای خرید و فروش در این پژوهش را شرح می‌دهیم.

نام این سیگنال RM می‌باشد. و به این صورت عمل می‌کند که زمانی که قیمت پیش بینی شده از ضریبی ثابت از قیمت فعلی، بزرگتر بود، سیگنال خرید می‌دهد و در صورتی که از ضریب ثابت دیگری از قیمت فعلی کمتر بود، سیگنال فروش می‌دهد. اگر هیچکدام از این شرایط صادق نبود، سیگنال خنثی می‌دهد و اعلام می‌کند که موقعیت خرید و یا فروش وجود ندارد. شبه کد این استراتژی به صورت زیر است:

---

<sup>1</sup> Active trading

زمانی که سیگنال خرید و فروش داده می شود، وابسته به وضعیت کیف پول، تصمیم به خرید و فروش می گیریم. در اینجا باید به دو مفهوم اشاره کنیم:

۱- پوزیشن خرید: زمانی که فرد در کیف پول خود، ارز پایه داشته باشد و بازار را در وضعیت صعودی مشاهده کند، میتواند معامله ی خرید انجام دهد و به اصلاح پوزیشن خرید ایجاد کند. این پوزیشن زمانی که فرد سود کافی برده باشد و یا بازار را در روند نزولی مشاهده کند، توسط فرد بسته می شود، یعنی معامله فروش انجام می دهد. در پوزیشن خرید، هزینه ی انجام معاملات  $0.2\%$  درصد در نظر گرفته شده است.

۲- پوزیشن فروش: این ویژگی از ویژگی های است که بعضی صرافی ها از جمله بایننس ارائه می دهند. فرض کنید که بازار در وضعیت نزولی قرار دارد و فرد هیچ رمز ارزی در کیف پول خود ندارد که از فروش آن سود کند. در این حالت فرد میتواند مقداری رمز ارز از صرافی قرض کند و آن را بفروشد. به این حرکت، باز کردن پوزیشن فروش می گویند. زمانی که بازار روند صعودی پیدا کرد، فرد میتواند پوزیشن خود را ببندد. در این حالت صرافی به اندازه ی سود انجام شده، ارز پایه در کیف پول فرد می ریزد و به ارزش بیتکوینی که به فرد قرض داده بود، از معامله رمز پایه برداشت می کند. در این معاملات هزینه ی خرید و فروش بالاتر از پوزیشن خرید است. ما در این پروژه این هزینه را مقدار ثابت  $0.25\%$  درصد در نظر گرفتیم.

حال اگر استراتژی بیان شده، سیگنال خرید باز گرداند و ما پوزیشن فروش باز داشتیم، در این حالت پوزیشن فروش خود را می بندیم و پوزیشن خرید باز می کنیم و به صورت



معکوس اگر سیگنال فروش باز گرداند، تمامی پوزیشن‌های خرید خود را می‌بندیم و پوزیشن فروش باز می‌کنیم. مشکلی که میتواند در این خرید و فروش وجود داشته باشد این است که اگر سیستم پیش‌بینی اشتباهی داشته باشد، ممکن است فرد ضرر زیادی کند. برای رفع این موضوع از مفهوم خط ایست ضرر<sup>1</sup> استفاده می‌کنیم. به این صورت که زمانی که پوزیشن خرید باز می‌کنیم و انتظار داریم که قیمت افزایش یابد، اگر پیش‌بینی اشتباه بود و قیمت کاهش پیدا کرد تنها تا ۰٫۰۵ درصد پایین‌تر از قیمت فعلی، ضرر را تحمل می‌کنیم و اگر قیمت به این خط رسید فوراً پوزیشن خود را می‌بندیم. همین‌طور زمانی که پوزیشن فروش باز می‌کنیم و انتظار داریم قیمت کاهش پیدا کند، حداکثر تا ۰٫۵ درصد بالاتر از قیمت فعلی، ضرر را تحمل می‌کنیم و زمانی که قیمت به این خط رسید، پوزیشن خود را می‌بندیم. این خطوط به ما کمک می‌کند که از ضرر بیش از حد جلوگیری کنیم.

---

Algorithm 1: RM Strategy

---

```

if predicted > (1 + rm_constant) * current_real_price:

    return buy

else if predicted < (1 - rm_constant) *
    current_real_price:

    return sell

else:
```

---

<sup>1</sup> Stop loss line

return neutral

## فصل 4

# نتایج

در این بخش به شرح نتایج حاصل از ارزیابی مدل‌های آموزش داده شده پرداخته شده است. تمامی مدل‌های آموزش داده شده در این پژوهش با استفاده از سخت افزار Graphics Processing

Unit (GPU) ارائه شده توسط سایت Google Colaboratory ارزیابی شده‌اند. مدل‌ها بر روی ۲ مجموعه داده با دوره‌های زمانی روزانه و ۱۵ دقیقه‌ای ارزیابی شده‌اند.

## ۱,۴ سیستم پیش بینی قیمت بیت کوین

در این قسمت به شرح نتایج به دست آمده از ارزیابی مدل‌ها با داده‌های تست، برای پیش بینی قیمت بیت کوین می‌پردازیم.


### ۱,۱,۴ نتایج مدل‌ها

در نمودار ۱,۴ نتایج مربوط به مدل LSTM با دوره زمانی روزانه برای پیش بینی قیمت بسته شدن روز بعد، برای داده های تست نشان داده شده است. این مدل برای ۴۰۰ دوره با سائز دسته‌ی ۷۲ با ۸۵ درصد داده‌ها آموزش دیده است. در این نمودار که مقدار قیمت روزانه را برای تاریخ ۲۰۲۱/۲/۲۳ تا ۲۰۲۱/۰۸/۲۵ پیش بینی کرده است، مشاهده می‌شود که پیش بینی و مقدار واقعی، بسیار به هم نزدیک هستند اما تنها ارزیابی بصری کافی نیست. برای ارزیابی این نتایج، از خطای RMSE استفاده کرده ایم. فرمول این خطا برابر است با:

(۴-۱)

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (x_i - y_i)^2}{N}}$$

که در آن  $N$  سائز دیتاست است،  $x_i$  مقدار واقعی قیمت و  $y_i$  مقدار پیش بینی شده برای آن دوره زمانی است.




شکل ۱/۴ نمودار پیش بینی مدل LSTM روزانه در کنار نمودار مقدار واقعی


میزان خطای RMSE برای این مدل و دیتاست روزانه برابر با 2196.39 گزارش شده است. که با توجه به رنج داده ها و نوسانات روزانه ی قیمت بیت کوین، مقدار مطلوبی است و نشان می دهد مدل دقت خوبی دارد. در نمودار مشاهده می شود که پیش بینی برای هر روز، بسیار به آن روز نزدیک است و حداکثر حدود ۳۰۰ دلار تفاوت دارند که این موضوع با توجه به نوسانات شدید قیمتی بیت کوین در طول یک روز، قابل توجیه است و در نتیجه انحراف معیار برای این مدل کوچک است. کوچک بودن انحراف معیار از این جهت اهمیت دارد که اگر از این سیستم برای معامله گری استفاده شود، در صورت تشخیص اشتباه مدل، ضررها محدود خواهد بود.

همانطور که پیشتر گفته شد، دو مدل LSTM با دیتاست های روزانه و ۱۵ دقیقه ای ایجاد کرده ایم. شکل ۲/۴ پیش بینی

قیمت توسط مدل LSTM با دوره زمانی ۱۵ دقیقه‌ای را نشان می‌دهد. این مدل در ۱۰۰ دوره با سائز دسته‌ی ۷۲ با ۷۰ درصد داده‌ها آموزش داده شده است. در این شکل قیمت بسته شدن در تایم فریم‌های ۱۵ دقیقه‌ای از تاریخ ۲۰۲۱/۰۷/۱۴ تا ۲۰۲۱/۰۹/۰۲ نمایش داده شده است که مجموعاً از 4815 تایم فریم تشکیل شده است. به دلیل تعداد بالای داده‌ها، به سختی می‌توان دو نمودار قیمت واقعی و قیمت پیش‌بینی شده را از هم تمییز داد، در نمودار ۳/۴ می‌توان نتایج این مدل را برای بازه‌ی کوتاه‌تری مشاهده کرد. همانطور که قابل رؤیت است، این مدل نسبت به مدل قبلی دقت بیشتری دارد، اولین دلیل آن این است که این مدل تعداد داده‌های بیشتری را برای آموزش داشته است و بنابراین می‌توان پیش‌بینی دقیق‌تری از قیمت بیت‌کوین داشته باشد، دومین دلیل آن هم این است که این مدل با تایم فریم کمتری پیش‌بینی انجام می‌دهد، میزان نوسانات در طول ۱۵ دقیقه بسیار محدودتر از نوسانات روزانه است. بنابراین طبیعی است که انطباق دو نمودار قیمت واقعی و قیمت پیش‌بینی شده، بیشتر از مدل قبلی باشد. در این مدل میزان خطای RMSE برابر با 309.40 بوده است. این صحبت قبلی ما را تایید می‌کند که این مدل دقیق‌تر از مدل با دیتاست با دوره زمانی روزانه است.




شکل ۲/۴ نمودار پیش بینی مدل LSTM با تایم فریم ۱۵ دقیقه ای در کنار نمودار مقدار واقعی



شکل ۳/۴ نمودار پیش بینی مدل LSTM با تایم فریم ۱۵ دقیقه ای برای ۵۰۰ داده ی انتهایی تست

پس از بررسی نتایج مدل LSTM به سراغ نتایج مدل GRU می‌رویم. همانند مدل LSTM، دو مدل GRU نیز با دیتاست با تایم فریم روزانه و ۱۵ دقیقه‌ای ایجاد کرده‌ایم.


ابتدا مدل GRU با دیتاست با تایم فریم روزانه را بررسی می‌کنیم. در شکل ۴/۴ می‌توانیم نمودار قیمت واقعی و نمودار پیش‌بینی این مدل را در کنار هم مشاهده کنیم. این مدل برای ۴۰۰ دوره با سائز دسته‌ی ۷۲ با ۸۵ درصد داده‌ها آموزش دیده است. در این نمودار مقدار قیمت روزانه را برای تاریخ ۲۰۲۱/۲/۲۳ تا ۲۰۲۱/۰۸/۲۵ پیش‌بینی کرده است. همانطور که در جدول ۱/۴ قابل مشاهده است این مدل نیز مانند مدل LSTM دقت خوبی دارد و خطای RMSE آن برابر با 2309.59 می‌باشد. اما تفاوتی که وجود دارد این است که در این مدل، تعداد نورون‌های کمتری استفاده شده است و همچنین هر نورون مدل GRU همانطور که پیش‌تر گفته شد، تعداد گیت‌های کمتری نسبت به مدل LSTM دارد و این باعث می‌شود که پیچیدگی کمتری داشته باشد. این مدل با وجود پیچیدگی کمتری که دارد، دقتی تقریباً مشابه با LSTM دارد. این باعث می‌شود که این مدل ارزش بیشتری داشته باشد. همچنین به دلیل استفاده از نورون‌های کمتر در جدول ۲/۴ مشاهده می‌شود که میزان زمان آموزش برای این مدل  $\frac{1}{4}$  زمان مورد نیاز برای آموزش مدل LSTM در شرایط مشابه است.



شکل ۴/۴ نمودار پیش بینی مدل GRU با تایم فریم روزانه در کنار نمودار مقدار واقعی


پس از این به سراغ بررسی نتایج مدل GRU با دیتاست با دوره‌ی زمانی ۱۵ دقیقه‌ای می‌رویم. این مدل در ۴۰۰ دوره و با سائز دسته‌ی ۷۲ آموزش داده شده است. در شکل ۵/۴ می‌توان نمودار پیش بینی این مدل را از تاریخ ۲۰۲۱/۰۷/۱۴ تا ۲۰۲۱/۰۹/۰۲ مشاهده کرد. در این نمودار مشابه LSTM با تایم فریم ۱۵ دقیقه‌ای، مشاهده می‌شود که دو خط قیمت واقعی و قیمت پیش بینی شده توسط مدل بسیار به یک دیگر نزدیک هستند.





شکل ۵/۴ نمودار پیش بینی مدل GRU با تایم فریم ۱۵ دقیقه ای در کنار نمودار مقدار واقعی

در شکل ۶/۴ می‌توانیم نمایی دقیق‌تر از پیش بینی این مدل را تنها برای ۵۰۰ تایم فریم انتهایی مشاهده کنیم.



شکل ۶/۴ نمودار پیش بینی مدل GRU با تایم فریم ۱۵ دقیقه ای برای ۵۰۰ داده ای انتهایی تست

طبق جدول ۱/۴، این مدل دقت بهتری نسبت به مدل LSTM با دیتاست مشابه دارد. شاید یکی از دلایلی که مدل GRU بهتر از LSTM عمل کرده است این باشد که LSTM پیچیدگی زیادی دارد و باعث می شود در هنگام آموزش مدل، نویزهای موجود را نیز مدل کند و در نتیجه دقت در داده های تست پایین تر باشد. در حقیقت مدل GRU معمولاً زمانی که سیستم پیچیدگی کمی دارد، دقت بهتری نسبت به مدل LSTM از خود نشان می دهد.

نام مدل	دوره ی زمانی دیتاست	میزان خطای RMSE
LSTM	روزانه	2196.39
LSTM	۱۵ دقیقه ای	309.40
GRU	روزانه	2309.59
GRU	۱۵ دقیقه ای	201.14

4354.16	روزانه	MA
352.14	۱۵ دقیقه ای	MA
2646.97	روزانه	SVR
1675.40	۱۵ دقیقه ای	SVR

جدول ۱/۴ خطای RMSE مدل‌های LSTM و GRU و MA و SVR


نام مدل	دوره‌ی زمانی دیتاست	مدت زمان آموزش (بر اساس ساعت، دقیقه و ثانیه)
LSTM	روزانه	0:01:25.229754
LSTM	۱۵ دقیقه ای	0:01:21.421925
GRU	روزانه	0:00:33.847371
GRU	۱۵ دقیقه ای	0:01:17.968012

جدول ۲/۴ مدت زمان آموزش مدل‌های LSTM و GRU

## ۲,۱,۴ مقایسه مدل‌ها با baseline ها


مدل‌های LSTM و GRU همانطور که مشاهده شد، برای دیتاست‌های یکسان، دقت‌های مشابهی داشتند. به همین دلیل برای بررسی اینکه آیا واقعاً مدل‌ها دقت مطلوبی دارند، از دو baseline استفاده می‌کنیم. همانطور که در فصل روش تحقیق شرح داده شد، از یک میانگین متحرک با دوره‌ی زمانی ۱۲ و یک مدل SVR به عنوان baseline استفاده کرده ایم.

نتایج پیش بینی داده های تست برای مدل SVR با دیتاست روزانه، در شکل ۷/۴ نمایش داده شده است، میزان خطای RMSE برای این مدل برابر با 2646.97 می باشد و برای داده ها با تایم فریم ۱۵ دقیقه ای، پیش بینی قیمت مدل SVR در شکل ۸/۴ نمایش داده شده است و میزان خطای RMSE برای این مدل برابر با 1675.40 است. همانطور که قابل مشاهده است دقت این مدل برای دیتاست روزانه، با دقت مدل های یادگیری ماشین تقریباً برابری می کند، اما در دیتاست با تایم فریم ۱۵ دقیقه ای دقت از همه ی مدل ها پایین تر است. یکی از دلایلی که می توان برای این توجیه این موضوع ارائه کرد، سایز دیتاست است. در مدل های دسته ی SVM پیچیدگی آموزش با افزایش سایز دیتاست افزایش می یابد و ماتریس هسته یک ماتریس  $N \times N$  است که N برابر با تعداد داده های آموزش است. بنابراین هر چه دیتاست بزرگتر شود، هم حافظه مورد نیاز به صورت درجه دوم<sup>1</sup> و هم زمان و پیچیدگی آموزش افزایش می یابد.



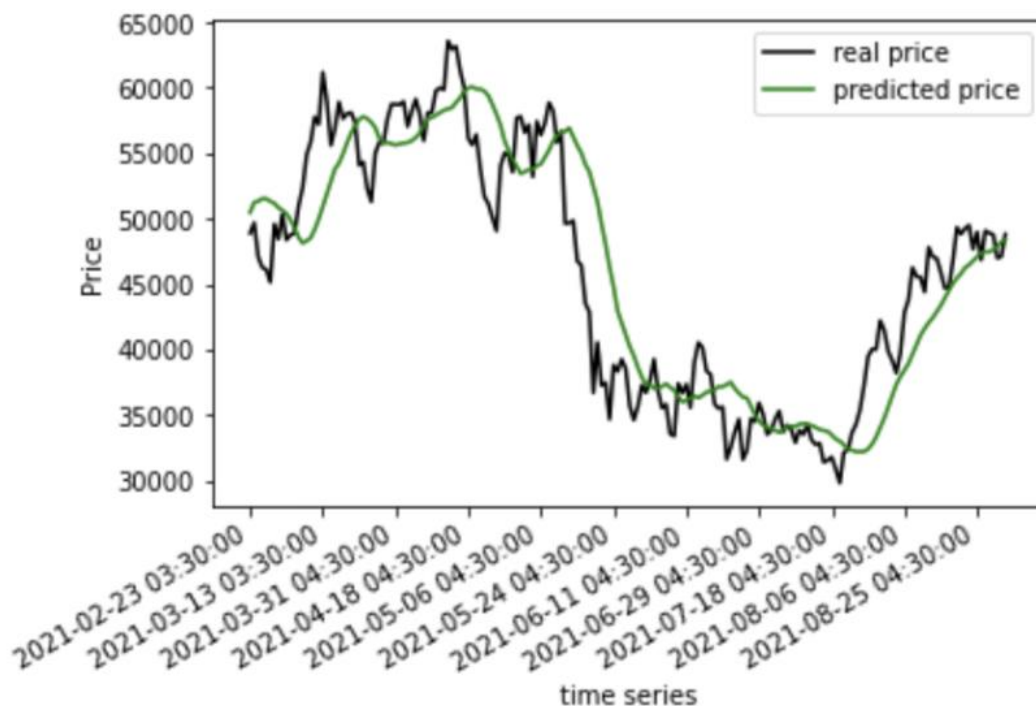
شکل ۷/۴ نمودار مدل SVR با دیتاست روزانه در کنار قیمت واقعی

<sup>1</sup> quadratically



شکل ۸/۴ نمودار مدل SVR با دیتاست با تایم فریم ۱۵ دقیقه‌ای در کنار قیمت واقعی

مدل میانگین متحرک با تایم فریم روزانه، در شکل ۹/۴ نمایش داده شده است. همانطور که قابل مشاهده است، این مدل حالت smooth شده‌ی همان قیمت واقعی است اما با یک تأخیر روندهای قیمت را دنبال می‌کند. دلیل آن هم این است که همواره میانگین قیمت ۱۲ روز گذشته را به‌عنوان پیش‌بینی برمی‌گرداند و بنابراین اگر در روز آخر قیمت افزایش یافته باشد، تنها به اندازه‌ی  $\frac{1}{12}$  روی پیش‌بینی تأثیر می‌گذارد. در جدول ۱/۴ مشاهده می‌کنیم که این مدل نسبت به مدل‌های یادگیری عمیق، خطای بیشتری دارد. بدیهی است که این مدل، یک مدل خطی است و از مدل‌های یادگیری عمیق که دارای وزن‌ها و لایه‌های پیچیده هستند طبیعتاً پیش‌بینی ضعیف‌تر و دقت کمتری دارد.



شکل ۹/۴ نمودار اندیکاتور میانگین متحرک ساده با دیتاست روزانه در کنار قیمت واقعی

برای مدل میانگین متحرک با تایم فریم ۱۵ دقیقه‌ای نیز این موضوع صادق است. در شکل ۱۰/۴ نمودار این مدل را مشاهده می‌کنیم. از آنجایی که تعداد داده‌ها زیاد است، در این نمودار خط‌ها براحتی قابل مشاهده نیست، اما با بررسی جدول ۴/۴ مشاهده می‌کنیم که این مدل دقت بیشتری نسبت به مدل‌های یادگیری عمیق با دیتاست مشابه دارد.



شکل ۱۰/۴ نمودار اندیکاتور میانگین متحرک ساده با دیتاست با تایم فریم ۱۵ دقیقه‌ای در کنار قیمت واقعی


## ۲/۴ نتایج ارزیابی مدل‌ها توسط سیستم معامله‌گری خودکار

همانطور که در فصل روش تحقیق شرح داده شد، برای بررسی کارایی مدل‌های یادگیری عمیق، از Back testing استفاده کرده ایم. به این صورت که روی خروجی مدل‌ها، استراتژی خرید و فروش را اعمال کردیم و سپس با توجه به این سیگنال و وضعیت کیف پول، پوزیشن خرید یا فروش ایجاد کردیم. در این قسمت نتایج حاصل از این استراتژی را بیان می‌کنیم.

برای ۳۲ روز گذشته، با استفاده از هر ۴ مدل، بک تست را اجرا کرده ایم. به این صورت که هم استراتژی خرید و نگهداری و هم استراتژی تعریف شده در این پژوهش را در یک نمودار مقایسه می‌کنیم.

در تمامی تست‌ها، ابتدا ۱۰۰ دلار در کیف پول خود داریم. در شکل ۱۱/۴ این تست را برای مدل LSTM با تایم فریم روزانه

مشاهده می‌کنیم. محور افقی تعداد تایم فریم‌هایی که در بازار حضور داریم را نشان می‌دهد. همانطور که مشخص است استراتژی RM سود کمتری نسبت به استراتژی خرید و نگهداری داشته است و هر ۳۲ روز را در بازار باشیم و در انتها از بازار خارج شویم، در حدود ۷٪ نسبت به مقدار سرمایه‌ی اولیه خود، سود کرده‌ایم. این مقدار برای استراتژی خرید و نگهداری در حدود ۱۰٪ سود است. این به این معناست که اگر از ۳۲ روز پیش، در اولین فرصت خرید (اولین باری که سیگنال خرید توسط استراتژی ما داده شده است)، یک خرید انجام می‌دادیم و در آخرین تایم فریم رمز ارز خود را می‌فروختیم، ۱۰ درصد خود می‌کردیم، اما در صورت استفاده از استراتژی ما، تنها ۵ درصد سود می‌کردیم.

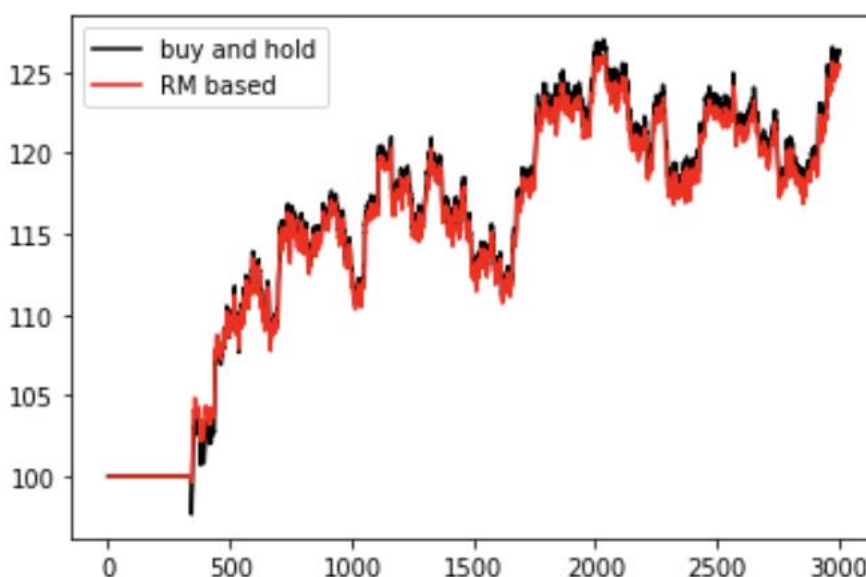


شکل ۱۱/۴ نتایج بک تست برای مدل LSTM با تایم فریم روزانه برای ۳۲ روز اخیر داده‌های تست

پس از تست این مدل برای داده‌های روزانه، به سراغ داده‌های با تایم فریم ۱۵ دقیقه‌ای رفتیم. در شکل ۱۲/۴ مشاهده




می‌شود که در استراتژی RM در ۳۰۰۰ تایم فریم، تعداد خرید و فروش‌های زیادی انجام نشده است و به همین دلیل با استراتژی خرید و نگهداری، نتایج تقریباً مشابهی داشته است. در مقایسه با همین مدل با دیتاست روزانه، مشاهده می‌کنیم که مدل فعلی عمل کرد قوی‌تری داشته است و در انتهای ۳۰۰۰ تایم فریم، ۲۵ درصد نسبت به سرمایه‌ی اولیه، سود اتفاق افتاده است. این در حالی است که در صورت استفاده از مدل با دیتاست روزانه و در حقیقت معامله‌گری به‌صورت روزانه، تنها ۵ درصد سود دریافت می‌کردیم. در دنیای واقعی نیز، افرادی که به‌صورت دقیقه‌ای قیمت‌ها را رصد می‌کنند، موقعیت‌های تغییر روند و یا قدرت روند بیشتری را نسبت به افرادی که روزانه معامله می‌کنند، مشاهده می‌کنند و در نتیجه می‌توانند از هر موقعیت کاهش و یا افزایش، سود به‌دست بیاورند.



شکل ۱۲/۴ نتایج بک تست بر مدل LSTM با تایم فریم ۱۵ دقیقه‌ای در ۳۲ روز اخیر

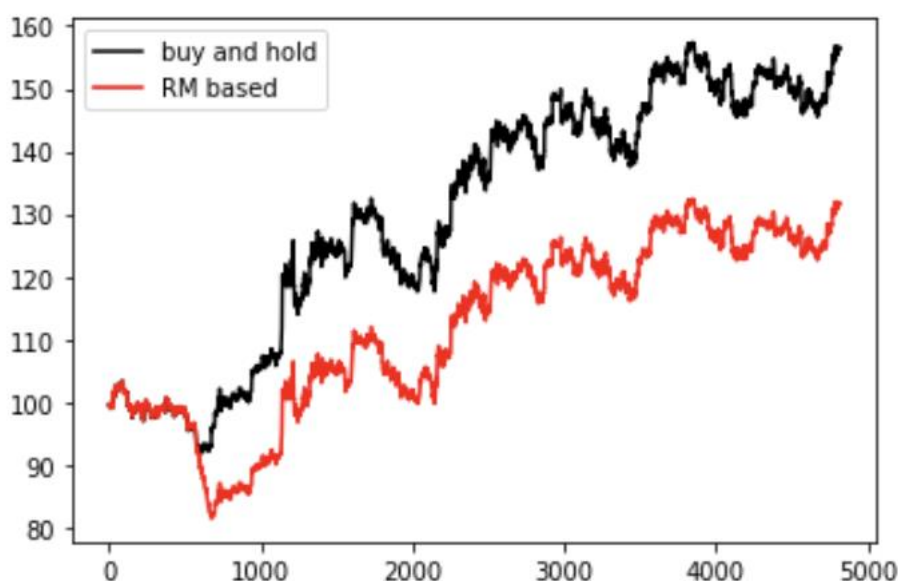
بعد از این به سراغ نتایج بک تست مدل GRU می‌رویم. در شکل ۱۳/۴ نتایج بک تست استراتژی RM برای مدل GRU با دیتاست روزانه را مشاهده می‌کنیم. این مدل به نسبت مدل LSTM، کمی سود کم‌تری داشته است اما به‌طور کلی بسیار مشابه هستند. این موضوع با وجود اینکه این مدل دقت مطلوب‌تر و ساختار ساده‌تری دارد، نتیجه‌ی مطلوبی نمی‌باشد و میتواند به دلیل عدم کارایی استراتژی تعریف شده باشد.



شکل ۱۳/۴ نتایج بک تست برای مدل GRU با تایم فریم روزانه برای ۳۲ روز اخیر داده‌های تست

بک تست برای مدل GRU با تایم فریم ۱۵ دقیقه نیز در شکل ۱۴/۴ نشان داده شده است. پس از بررسی این تست نیز متوجه می‌شویم که سود این مدل نیز با سود مدل LSTM با دیتاست مشابه، تقریباً یکسان است. اما از مدل GRU با دیتاست روزانه، عمل کرد بهتری داشته است. در استراتژی خرید و نگهداری افزایش سود زیادی را مشاهده می‌کنیم (در حدود ۶۰ درصد سود در صورت ماندن در بازار به مدت ۳۲ روز). حال آنکه سود حاصل از استراتژی RM در صورت ماندن در بازار در تمام

این مدت، به اندازه ۲۵ درصد مقدار سرماییهی اولیه است. البته لازم به ذکر است که استراتژی خرید و نگهداری نیز برای خرید، از سیگنال RM استفاده می‌کند. بنابراین به نوعی متاثر از این سیگنال عملکرد خوبی داشته است.



شکل ۱۴/۴ نتایج بک تست بر مدل GRU با تایم فریم ۱۵ دقیقه‌ای در ۳۲ روز اخیر

در انتها به نظر میرسد که استراتژی مطرح شده با توجه به وضعیت نوسانی بیت کوین، ساده لوحانه می‌باشد و برای این سیستم پیچیده، مناسب نیست و باید متغیرهای بیشتری را برای دادن سیگنال خرید و فروش در نظر گرفت.

## فصل 5

### نتیجه گیری

هدف اصلی این تحقیق، ارائه‌ی یک سیستم پیش‌بینی قیمت بیت‌کوین با استفاده از مدل‌های هوش مصنوعی بوده است و در این تحقیق مدل‌های LSTM و GRU از دسته مدل‌های RNN به‌عنوان مدل‌های پیش‌بینی قیمت آموزش داده شده‌اند. امروزه بعضی معامله‌گران در حوزه‌ی رمز ارز، به‌صورت روزانه و بعضی دیگر در فاصله‌های زمانی کوتاه‌تر و در حدود دقیقه به معامله می‌پردازند به همین دلیل از دو دیتاست یکی به‌صورت روزانه و دیگری با تایم فریم برابر با ۱۵ دقیقه استفاده کردیم. برای جمع‌آوری این اطلاعات از صرافی نوبیتکس و از API مناسب ارائه شده در داکيومنت API های صرافی نوبیتکس، استفاده کردیم. برای هر دیتاست، یک مدل LSTM و یک مدل GRU با پارامترهای مناسب آموزش دادیم. این مدل‌ها، به‌عنوان ورودی اطلاعات یک بازه‌ی زمانی را دریافت می‌کنند و قیمت بسته شدن را برای تایم فریم بعدی پیش‌بینی می‌کنند. در نتایج مشاهده کردیم که از میان این دو مدل، مدل GRU با وجود اینکه

ساختار ساده تری نسبت به LSTM دارد، اما خطای کمتری نسبت به داده‌های واقعی دارد. برای مقایسه‌ی دقت مدل‌های LSTM و GRU از یک میانگین متحرک ساده و SVR به‌عنوان baseline استفاده کردیم. در نهایت از آنجا که قرار است این سیستم پیش‌بینی قیمت بیت‌کوین، برای معامله‌گری استفاده شود، نیاز بود تا روی تعدادی از تایم فریم‌های گذشته، از این پیش‌بینی استفاده کنیم و یک back testing ایجاد کنیم و میزان سود و ضرر حاصل از استفاده از این مدل‌ها را مشاهده کنیم. برای این امر یک استراتژی خرید و فروش تعریف کردیم که در صورتی که کیف پول شرایط لازم را داشته باشد با این استراتژی به‌صورت خودکار به معامله بپردازد. در انتها مشاهده کردیم که در صورتی که از این استراتژی استفاده کنیم، میزان سود کمتر از حالتی است که از استراتژی خرید و نگهداری استفاده کنیم. نتایج حاصل از این بخش می‌توان بیانگر این باشد که استراتژی تعریف شده، به اندازه‌ی کافی برای معامله کردن مناسب نیست.

یکی از مهم‌ترین محدودیت‌های این تحقیق، عدم داشتن دانش کافی ما از حوزه‌ی معامله رمزارزها و استراتژی‌های موجود برای خرید و فروش است. با وجود خطای پایین مدل‌های یادگیری عمیق ما، به دلیل داشتن استراتژی بسیار ساده برای معامله، بخوبی از این سیستم پیش‌بینی قیمت استفاده نشده است. اما داشتن استراتژی‌های پیشرفته، نیازمند این است که برای قیمت پیش‌بینی شده درصد اطمینان از پیش‌بینی را نیز داشته باشیم. این امر با توجه به بازار نوسانی قیمت بیت‌کوین دشوار است. در کارهای آینده در صورتی که بتوان برای پیش‌بینی‌های خود، درصد اطمینان مشخص کرد، می‌توان استراتژی‌های پیچیده تری ایجاد کرد که از پیش‌بینی‌های انجام شده،

بیشترین بهره را ببرد و در نتیجه انتظار می‌رود سود بیشتری در معاملات خودکار به دست آید.

مراجعه

- [1] Nakamoto, Satoshi. "Bitcoin." *A peer-to-peer electronic cash system* (2008).
- [2] Amjad, Muhammad, and Devavrat Shah. "Trading bitcoin and online time series prediction." *NIPS 2016 Time Series Workshop*. PMLR, 2017.
- [3] Felizardo, Leonardo, et al. "Comparative study of Bitcoin price prediction using WaveNets, Recurrent Neural Networks and other Machine Learning Methods." *2019 6th International Conference on Behavioral, Economic and Socio-Cultural Computing (BESC)*. IEEE, 2019.
- [4] Jang, Huisu, and Jaewook Lee. "An empirical study on modeling and prediction of bitcoin prices with bayesian neural networks based on blockchain information." *Ieee Access* 6 (2017): 5427-5437.
- [5] Radityo, Arief, Qorib Munajat, and Indra Budi. "Prediction of Bitcoin exchange rate to American dollar using artificial neural network methods." *2017 International Conference on Advanced Computer Science and Information Systems (ICACISIS)*. IEEE, 2017.
- [6] Khedmati, M., F. Seifi, and M. J. Azizi. "Time Series Forecasting of Bitcoin Price Based on Autoregressive Integrated Moving Average and Machine Learning Approaches." *International Journal of Engineering* 33.7 (2020): 1293-1303.
- [7] Phaladisailoed, Thearasak, and Thanisa Numnonda. "Machine learning models comparison for bitcoin price prediction." *2018 10th International Conference on Information Technology and Electrical Engineering (ICITEE)*. IEEE, 2018.
- [8] Hitam, Nor Azizah, Amelia Ritahani Ismail, and Faisal Saeed. "An optimized support vector machine (SVM) based on particle swarm optimization (PSO) for cryptocurrency forecasting." *Procedia Computer Science* 163 (2019): 427-433.

- [9] Silva, Thalita R., Audeliano W. Li, and Edson O. Pamplona. "Automated Trading System for Stock Index Using LSTM Neural Networks and Risk Management." 2020 International Joint Conference on Neural Networks (IJCNN). IEEE, 2020.
- [10] Wu, Chih-Hung, et al. "A new forecasting framework for bitcoin price with LSTM." 2018 IEEE International Conference on Data Mining Workshops (ICDMW). IEEE, 2018.
- [11] McNally, Sean, Jason Roche, and Simon Caton. "Predicting the price of bitcoin using machine learning." 2018 26th euromicro international conference on parallel, distributed and network-based processing (PDP). IEEE, 2018.
- [12] Huang, Jing-Zhi, William Huang, and Jun Ni. "Predicting Bitcoin returns using high-dimensional technical indicators." *The Journal of Finance and Data Science* 5.3 (2019): 140-155.
- [13] Ji, Se-Hyun, et al. "Best Feature Selection using Correlation Analysis for Prediction of Bitcoin Transaction Count." 2019 20th Asia-Pacific Network Operations and Management Symposium (APNOMS). IEEE, 2019.
- [14] Fang, Fan, et al. "Cryptocurrency trading: a comprehensive survey." *arXiv preprint arXiv:2003.11352* (2020).





University of  
Tehran



College of Engineering

School of Electrical and Computer Engineering

## **Bitcoin Price Prediction System**

Bachelor of Science Thesis in Software Engineering

By:

**Nastaran Alipour**

Supervisor:

**Dr. Hesham Faili**